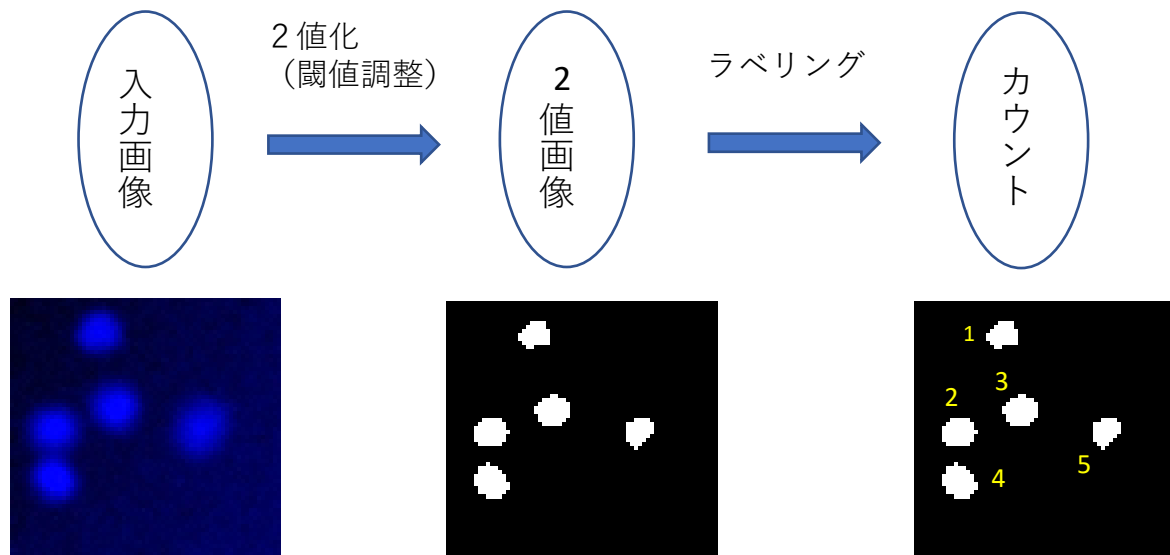


2019年9月13日

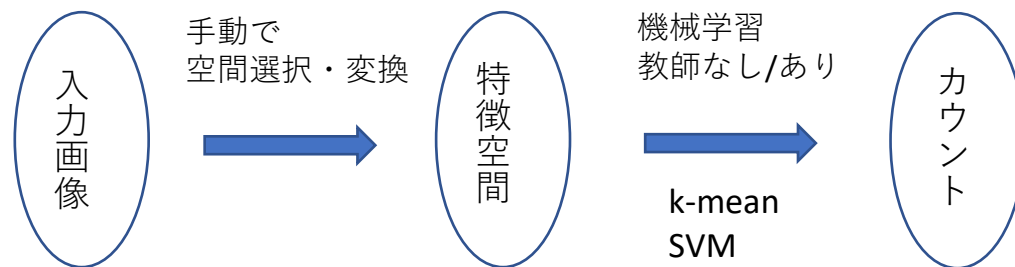
# 敵対的生成ネットワークを用いた 教師なし物体カウント

@samacoba

### ・手動の 画像処理



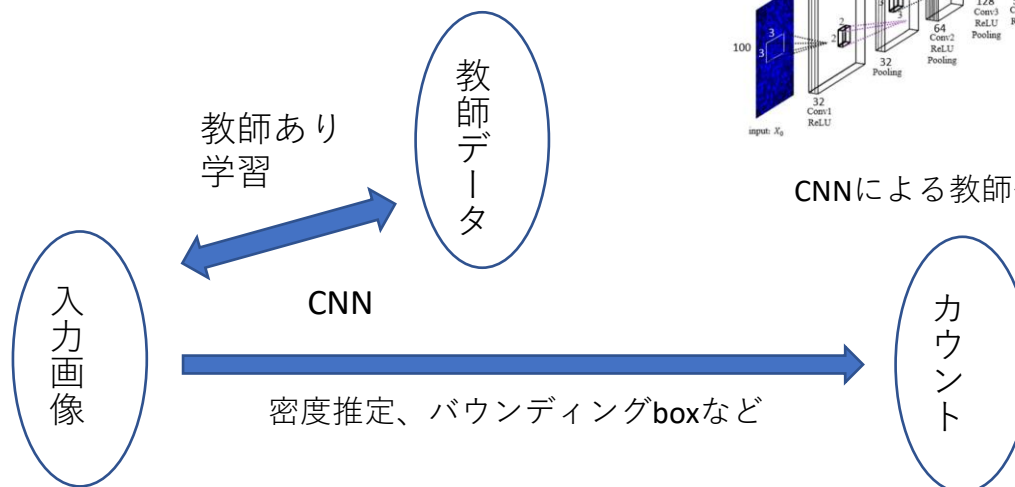
### ・前処理 + 機械学習



- ・ 画像を見て、人間が処理内容の選択やパラメータの調整が必要
- ・ 画像のタイプが異なると修正が必要

## 研究背景

- 教師付き  
End-to-End  
深層学習



CNNによる教師付きカウント例[1]

⇒学習に教師データが必要

## 研究目標

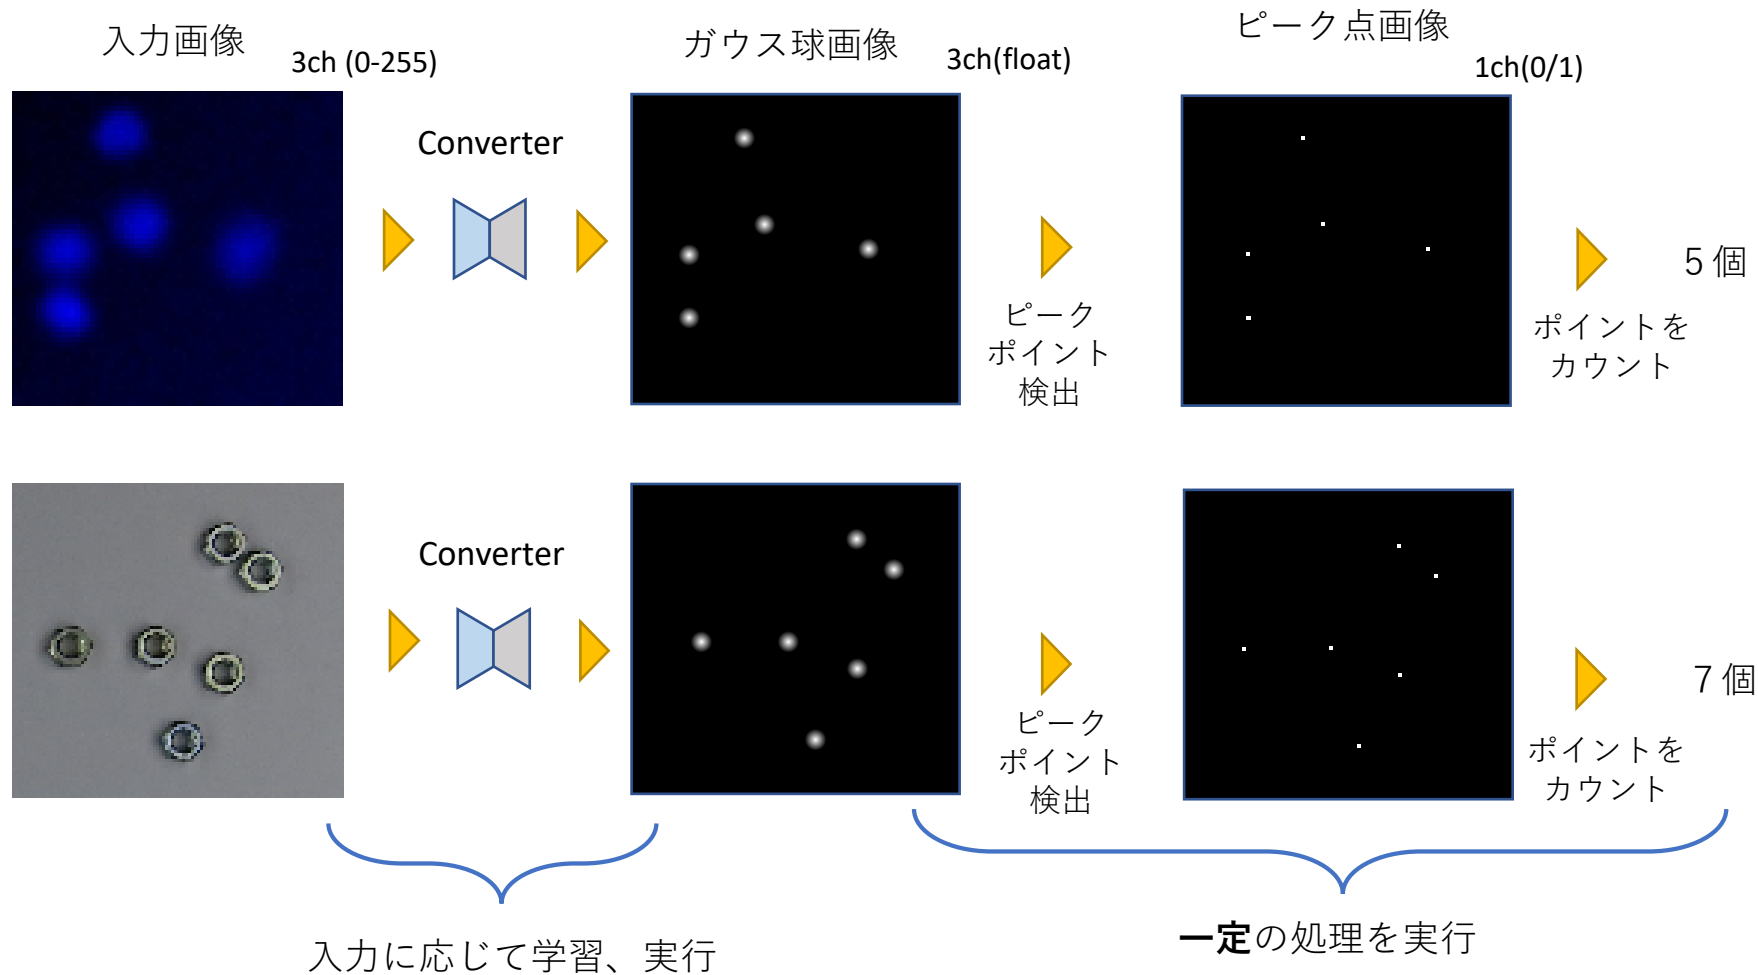
前処理なし・教師なしで、 多様なオブジェクトの検出・カウントを目指す

人間が物体に合わせて  
特徴選択や抽出をしない

色・テクスチャ・形状にかかわらず

[1]Weidi Xie, et al. "Microscopy cell counting and detection with fully convolutional regression networks"  
COMPUTER METHODS IN BIOMECHANICS AND BIOMEDICAL ENGINEERING: IMAGING & VISUALIZATION  
VOL. 6, NO. 3, 283–292(2018)

# 提案手法 ・ アプローチ方法



入力に応じて「Converter」が学習できれば、  
一定の処理でカウントが可能

⇒教師なしで「Converter」が学習できることが目標

※ピークポイントの検出例

0	0	10	0	0
0	10	30	10	0
10	30	50	30	10
0	10	30	10	0
0	0	10	0	0



10	30	30	30	10
30	50	50	50	30
30	50	50	50	30
30	50	50	50	30
10	30	30	30	10

0	0	0	0	0
0	0	0	0	0
0	0	50	0	0
0	0	0	0	0
0	0	0	0	0


3 × 3 Max Pooling

$A^*(A=B)$

## 提案手法

### ・学習時の入力データ


入力画像A




$3\text{ch} \times 512 \times 512 \times 1\text{枚}$

位置は一致していない

ランダムガウス球画像B



$3\text{ch} \times 512 \times 512 \times 10\text{枚}$



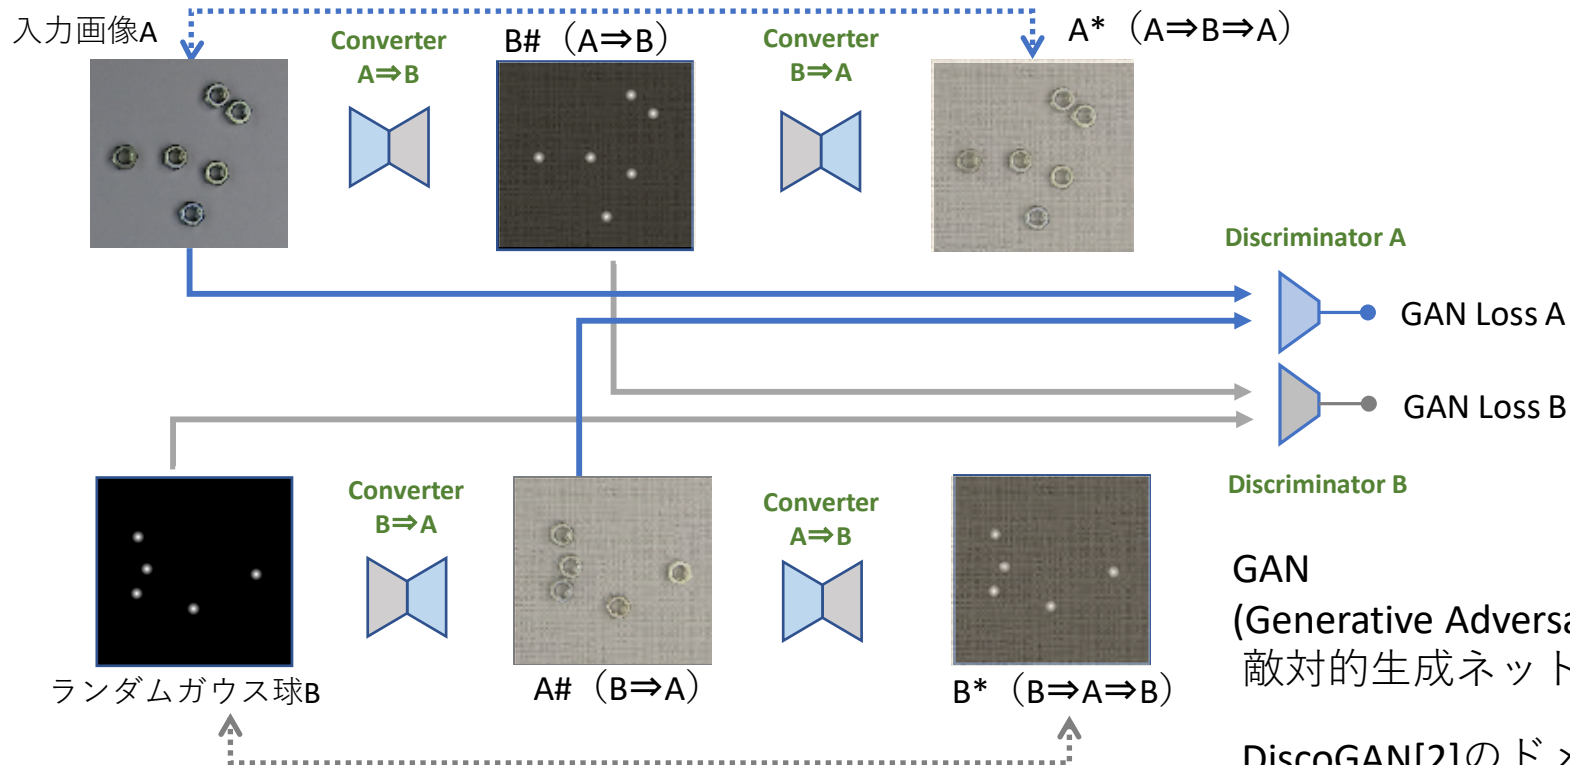
入力画像と**同オーダ**の数の  
ガウス球をランダムな位置  
ばらまいて**生成する**

※「ヒント」を与えているので、完全な教師なしではない


入力画像Aとランダムガウス球画像Bを $64 \times 64 \times 100$ 枚ずつ切り取り、  
4種類のDeep Neural Networkを学習させる

• Converterの学習

Reconstruct Loss A



• Converterの詳細



GAN

(Generative Adversarial Networks)

敵対的生成ネットワーク


DiscoGAN[2]のドメイン変換

学習ネットワークを転用




[2]Taeksoo Kim, et al. "Learning to Discover Cross-Domain Relations with Generative Adversarial Networks", ICML(2017)

## I.細胞核画像[3]



- ・細胞核の蛍光顕微鏡画像を合成して作成したサンプル（実画像ではない）
- ・画像枚数：200枚
- ・平均個数：176.0個
- ・最大個数：317個
- ・最小個数：74個

## II.ナット撮影画像



- ・六角ナット(M3、鉄製、ユニクロメッキ、YAHATA)
- ・画像枚数：10枚
- ・個数：すべて100個
- ・1枚ごとにランダム配置を変えて撮影
- ・光源、距離、カメラ設定は固定

# 比較手法

## ①大津の2値化[4]

白黒反転  
Orそのまま

グレー  
スケール化

大津の  
2値化

ラベリング

面積 $\alpha$ 以  
下カット

カウント

$\alpha$ の手動調整あり

## ②Blob検出器[5] (Laplacian of Gaussian)

白黒反転  
Orそのまま

グレー  
スケール化

Blob検出  
(Laplacian of Gaussian)

カウント

Max sigma, Min sigma, Threshold  
の手動調整あり

## ③ピークポイント検出

白黒反転  
Orそのまま

グレー  
スケール化

ピークポイント  
の抽出

輝度 $\beta$ 以  
下カット

カウント

$\beta$ の手動調整あり

## ④提案手法

教師なし  
Converの学習

学習済Converにより  
ガウス球画像へ変換

③ピークポイント抽出

カウント

白黒反転なし、 $\beta$ は固定

※「ヒント」としてばらまくガウス球の個数は平均正解個数を使用


## ⑤教師ありCNN[1]

教師(N=8)あり  
CNN密度推定学習

学習済CNNにより  
密度推定画像へ変換


個数を推定

大津の2値化



<https://qiita.com/haru1843/items/00de955790d3a22a217b>

ラプラシアン・ガウシアンフィルタ



画像認識 原田達也(2017)

[4] Nobuyuki Otsu "A threshold selection method from gray-level histograms".  
IEEE Trans. Sys., Man., Cyber. 9(1): 62–66 (1979).

[5] L. Bretzner & T. Lindeberg. "Feature Tracking with Automatic Selection of Spatial Scales" Computer Vision and Image Understanding. 71 (3): 385–392 (1998) .



# 結果

入力 + カウント位置 (赤円)

Converter 出力



出力例：④提案手法

## I. 細胞核画像

正解数：135

出力数：131

abs Err：4





## II. ナット撮影画像

正解数：100

出力数：100



abs Err：0



## I .細胞核画像

	平均値	
	出力数	abs Err
正解	176.0	—
① 大津の2値化	76.6	99.4
② blob検出器	161.2	15.2
③ ピークポイント検出	171.9	8.6
④ 提案手法	144.3	37.1
⑤ 教師ありCNN[1]	—	3.9


出力例：①大津の2値化




## Ⅱ. ナット撮影画像

サンプル	正解数	①大津の2値化		②blob検出器		③ピークポイント検出		④提案手法	
		出力数	abs Err	出力数	abs Err	出力数	abs Err	出力数	abs Err
img0	100	127	27	99	1	90	10	101	1
img1	100	133	33	99	1	61	39	100	0
img2	100	126	26	101	1	70	30	95	5
img3	100	124	24	102	2	77	23	100	0
img4	100	122	22	101	1	53	47	100	0
img5	100	128	28	99	1	63	37	94	6
img6	100	128	28	103	3	60	40	100	0
img7	100	125	25	102	2	62	38	89	11
img8	100	127	27	102	2	55	45	100	0
img9	100	113	13	101	1	37	63	100	0
平均	100	125.3	<b>25.3</b>	100.9	<b>1.5</b>	62.8	<b>37.2</b>	97.9	<b>2.3</b>

出力例：①大津の2値化



出力例：③ピークポイント検出



## まとめ

- ・ **GAN**を使用した提案手法により、細胞核画像、ナット撮影画像の**2種類**にて、教師なし物体検出・カウントが可能であることを示した

## 今後の予定

- ・ 他の複数の種類のデータに提案手法が対応可能かテストを行う
- ・ 教師なしだけでなく、一部の物体位置を与える半教師付きにて実験を行う
- ・ 2クラス以上の物体に対して、検出・類別可能か実験を行う