

# IBIS2019 ポスター＋補足資料

2019.11.19



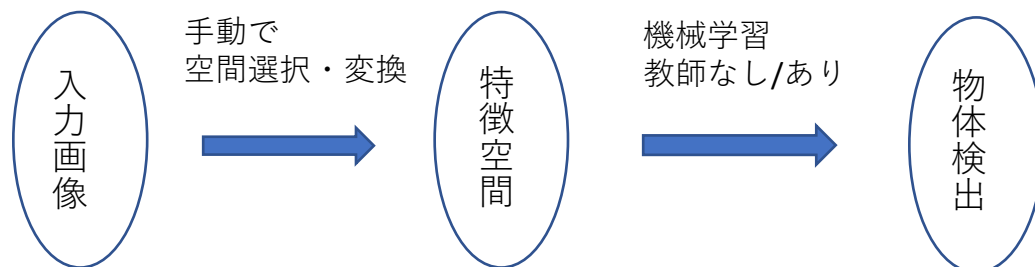
さまこば@samacoba



E-mail: samacoba @outlook.jp

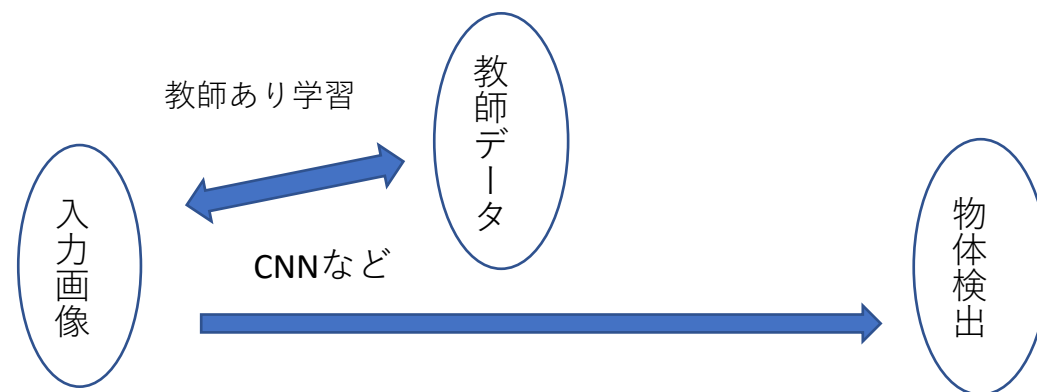
## 研究背景

・前処理  
+ 機械学習



前処理に  
人の労力が必要

・教師あり  
深層学習



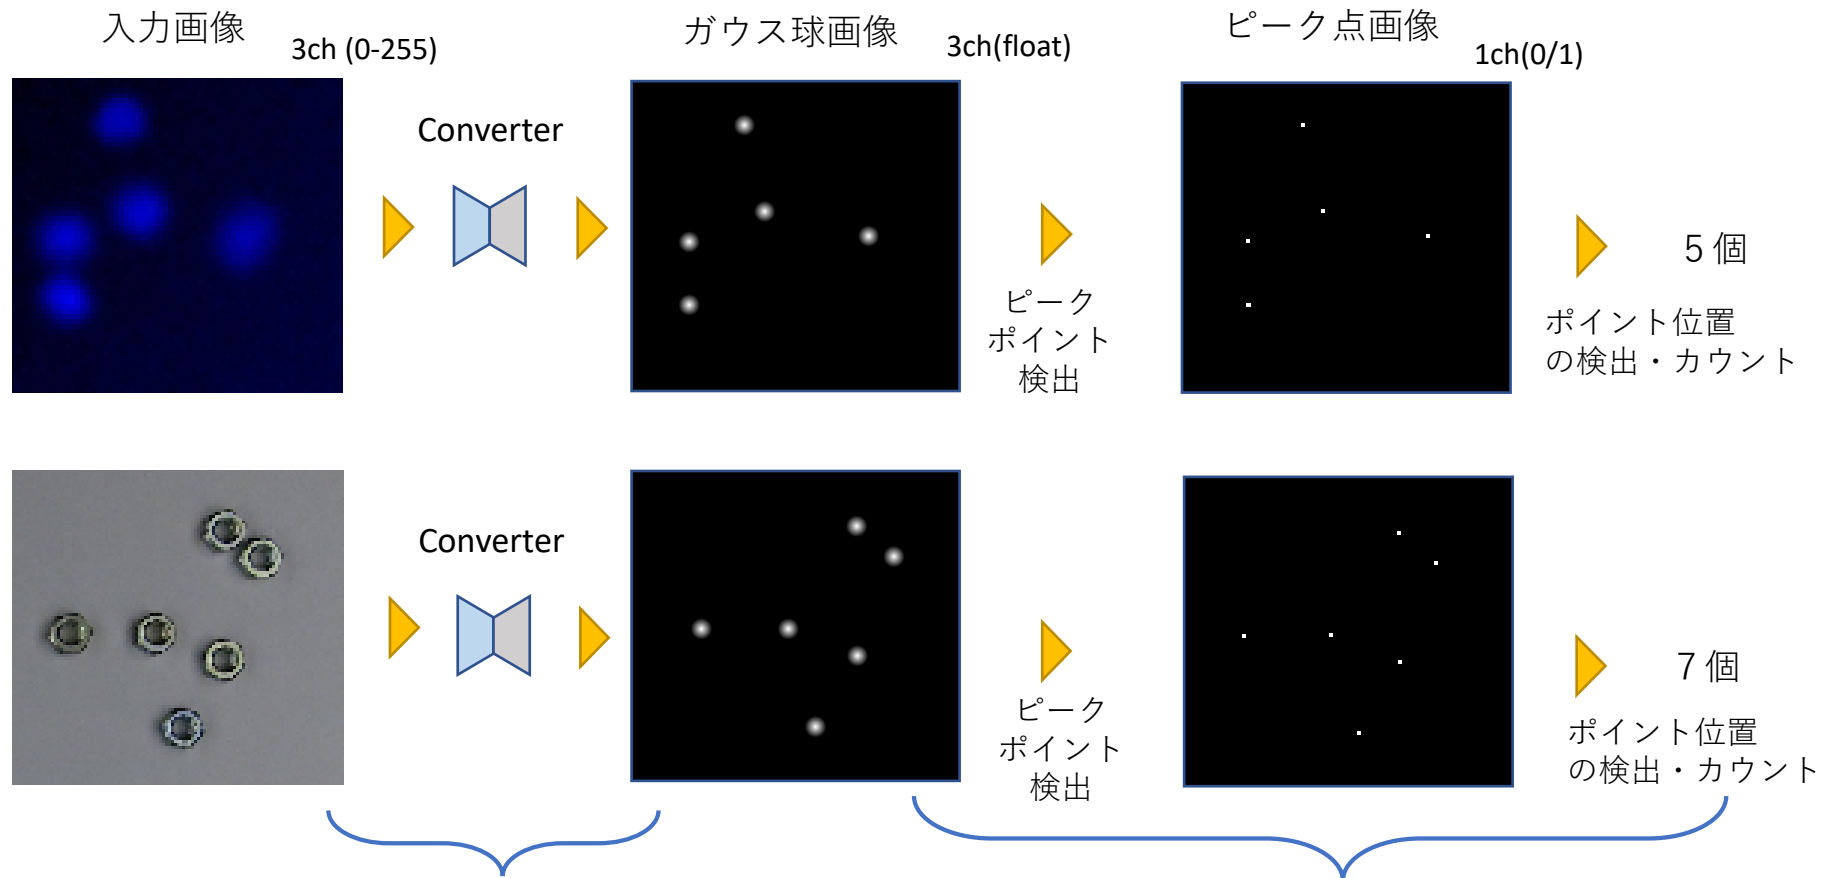
教師データ作成に  
人の労力が必要

## 研究目標

前処理なし・教師なしで、 多様なオブジェクトの検出・クラス分けを目指す

↑  
人間が物体に合わせて  
特徴選択や抽出をしない

↑  
色・テクスチャ・形状にかかわらず



入力に応じて「Converter」が学習できれば、  
一定の処理で検出が可能

**本研究では教師なしで検出しやすい画像に変換することを目指す**

一定の処理を実行

※ピークポイントの検出例

0	0	10	0	0
0	10	30	10	0
10	30	50	30	10
0	10	30	10	0
0	0	10	0	0



10	30	30	30	10
30	50	50	50	30
30	50	50	50	30
30	50	50	50	30
10	30	30	30	10

0	0	0	0	0
0	0	0	0	0
0	0	50	0	0
0	0	0	0	0
0	0	0	0	0


3 × 3 Max Pooling

$A^*(A=B)$

## 提案手法


### ・学習時の入力データ

入力画像A




$3\text{ch} \times 512 \times 512 \times 1\text{枚}$

ランダムガウス球画像B



$3\text{ch} \times 512 \times 512 \times 10\text{枚}$

位置は一致していない



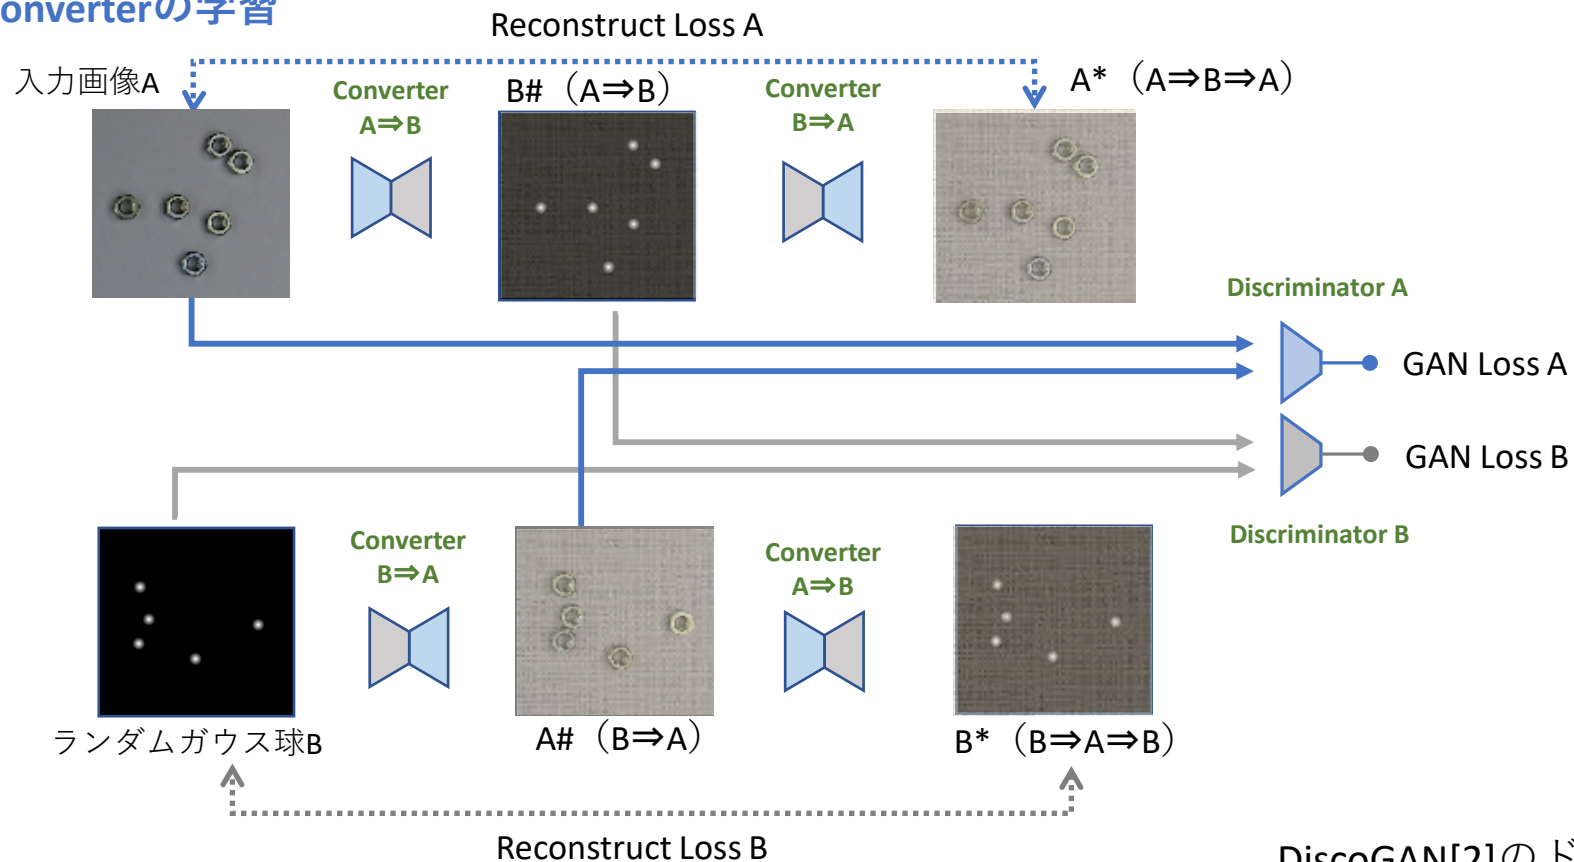
入力画像と**同オーダ**の数のガウス球をランダムな位置に散在させて**生成する**

※ 与えるガウス球の平均の**散布数**は重要なパラメータ


「**ヒント**」を与えているため、完全な教師なしではない

入力画像Aとランダムガウス球画像Bを $64 \times 64 \times 100$ 枚ずつ切り取り、  
4種類のDeep Neural Networkを学習させる

## • Converterの学習



## • Converterの詳細




DiscoGAN[2]のドメイン変換  
学習ネットワークを転用



[1]Taeksoo Kim, et al. "Learning to Discover Cross-Domain Relations with Generative Adversarial Networks", ICML(2017)

## 実験対象データ

### I .細胞核画像[2]




- ・細胞核の蛍光顕微鏡画像を合成して作成したサンプル（実画像ではない）
- ・画像枚数：200枚
- ・平均個数：176.0個
- ・散布数：176個
- ・最大個数：317個
- ・最小個数：74個

### II .ナット撮影画像



- ・六角ナット(M3)
- ・個数：25個、50個、100個
- ・散布数：正解数の20%, 40%, ....., 300%
- ・画像枚数：各5枚
- ・1枚ごとにランダム配置を変えて撮影
- ・光源、距離、カメラ設定は固定

### III .2色ビーズ画像



- ・2色ビーズ
- ・個数：青50個、赤50個
- ・散布数：60個、60個
- ・画像枚数：各5枚
- ・1枚ごとにランダム配置を変えて撮影
- ・光源、距離、カメラ設定は固定


[2]Lempitsky V, Zisserman A. "Learning to count objects in images" , NIPS(2010)

### I. 細胞核画像

正解数：135個

散布数：176個

出力数：126個

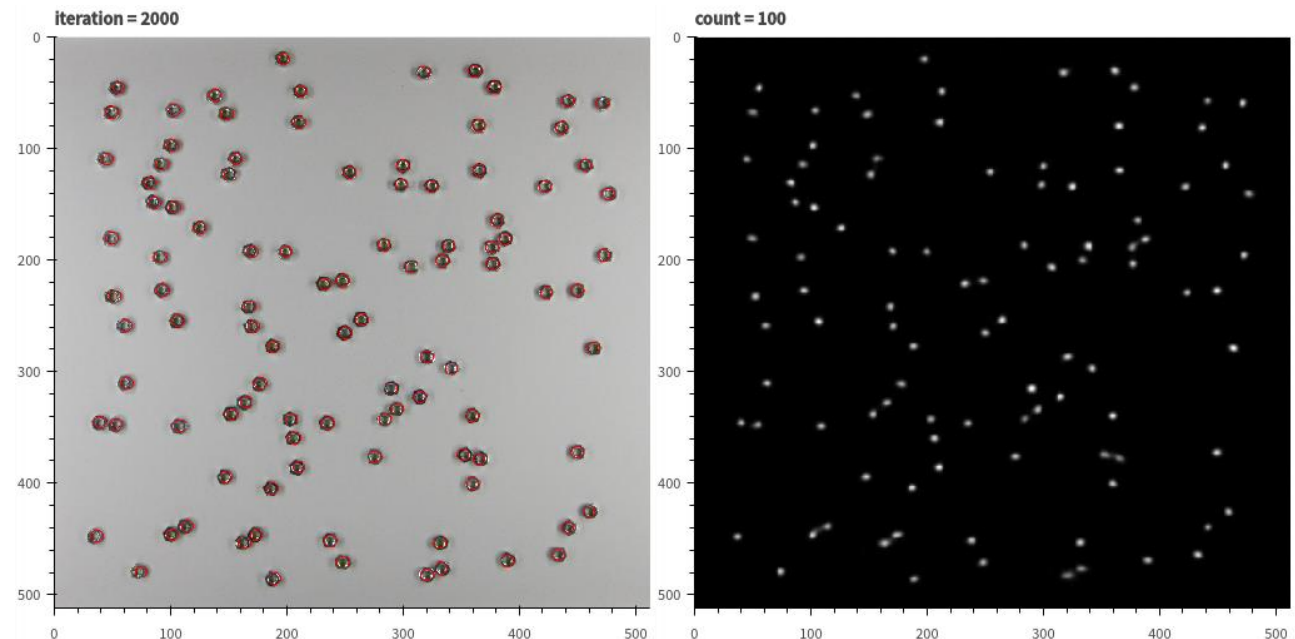


### II. ナット撮影画像

正解数：100個

散布数：120個


出力数：100個



## ・正解数、散布数、出力数の関係


### I.細胞核画像

散布数: : 176個



散布数より正解数が少ない領域の結果が良好

### II.ナット撮影画像

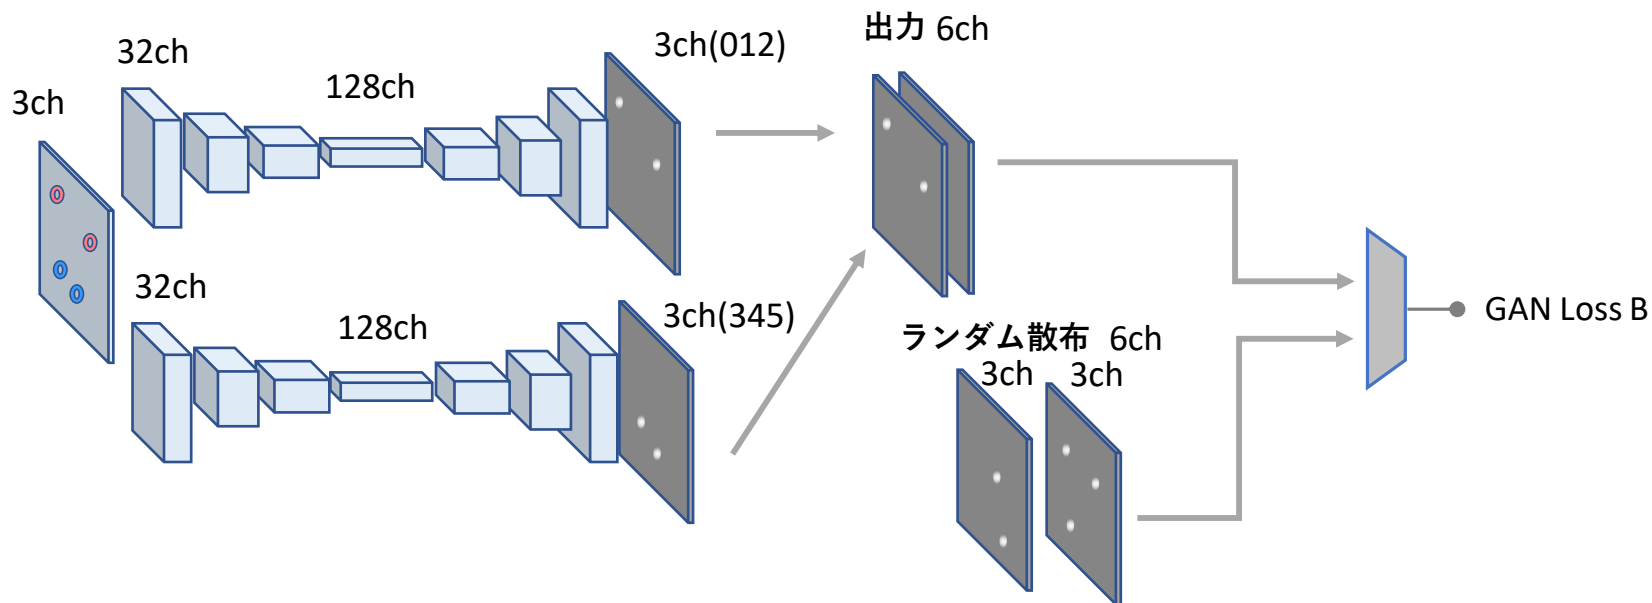


正解数の100-220%程度の散布数の結果が良好



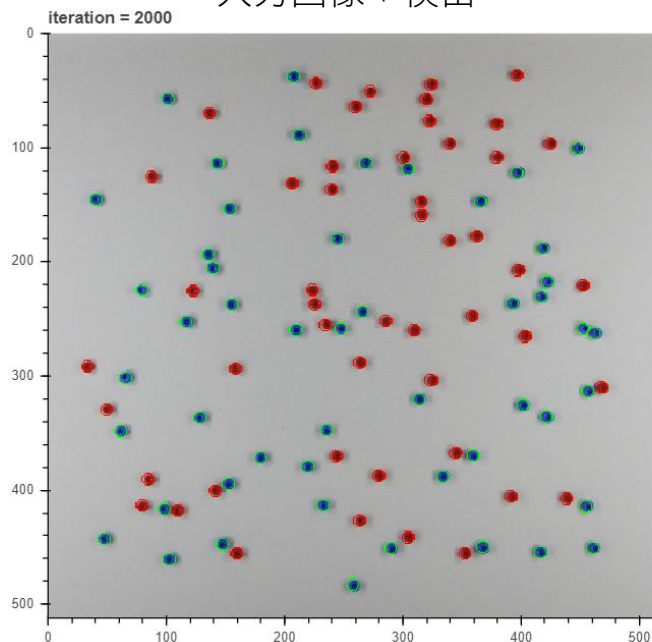
## 2クラス分類

2クラス用  
ネットワーク




Ⅲ. 2色ビーズ画像 正解数：青50個,赤50個 散布数：60個,60個 出力数：50個,50個


入力画像 + 検出



出力(012)ch



出力(345)ch





## 結論

- ・ **GAN**を使用した提案手法により、細胞核画像、ナット撮影画像、2色ビーズ画像の3種類にて、検出しやすい画像への変換に成功した。

補足資料


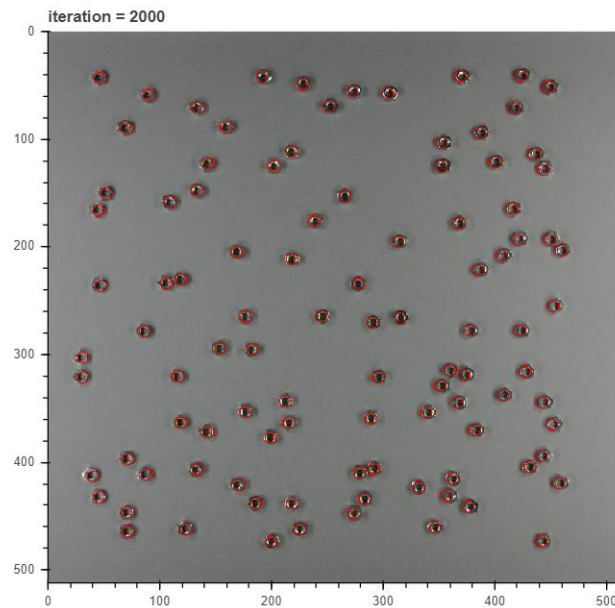
## 撮影装置概要




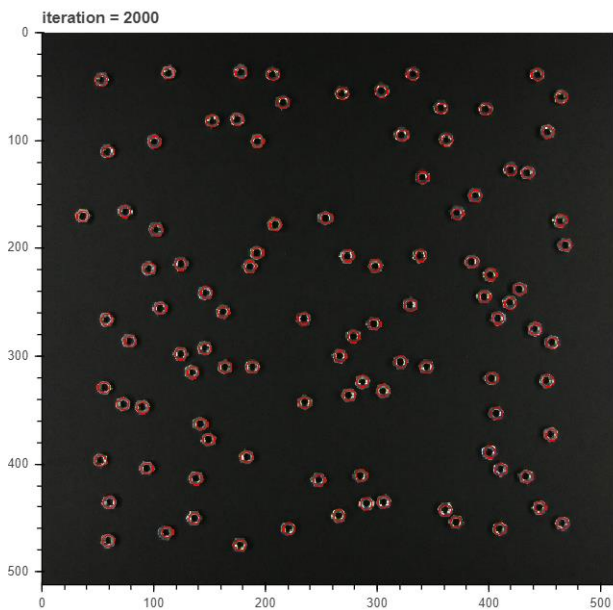
- ・ 照明が均一、直反射が少ない、影が少ないなど位置を調整
- ・ サンプルは撮影毎に「手」でランダム風に置きなおしている  
(厳密なランダムではない)

- 背景の違い

グレー背景


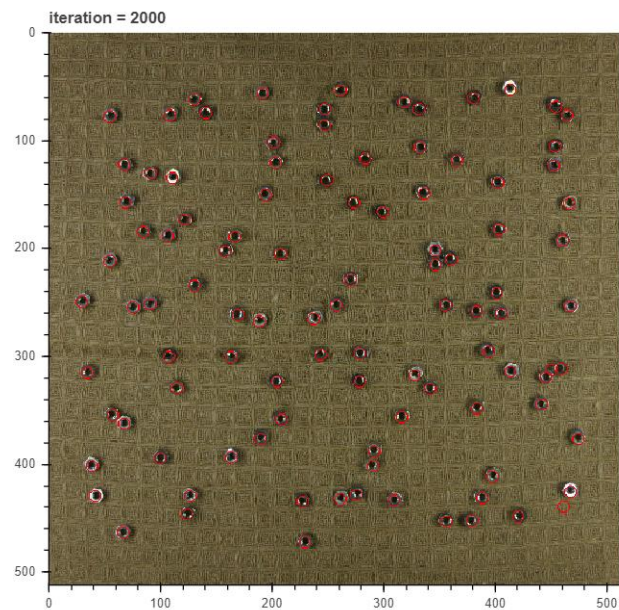


黒背景





- 背景の違い

ワッフル生地背景




コルク背景




## 少数サンプル

入力画像は  $256 \times 256$

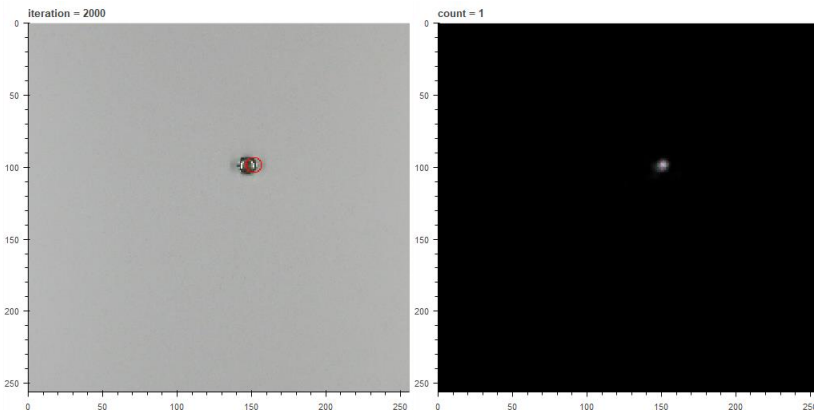
0個




2個



1個









3個











## ナット&ワッシャー






## 2色ビーズ






## 3色ビーズ



## 色割合




クラス① 赤 R:G:B = 10:0:0

クラス② 青 R:G:B = 0:0:10






クラス①赤紫 R:G:B = 6:0:4

クラス②青紫 R:G:B = 4:0:6






## テクスチャ

クラス① 1pixelパターン    クラス② 2pixelパターン



## 記号

クラス① + (プラス)    クラス② ○ (マル)



+ ○ ○

記号は現状厳しい